

Praca magisterska

Marcin Bartodziej

8 maja 2025

Spis treści

1	Opis eksperymentów	5
2	Wstępny przegląd danych	7
2.1	Dane: Computers	7
2.2	Dane: Car	8
3	Metoda najbliższego sąsiada 1-NN	11
3.1	Dane: Computers	11
3.1.1	Ogólny przegląd metod	11
3.1.2	Wpływ parametrów na poszczególne metody	12
3.1.3	Analiza stabilności metod	13
3.2	Dane: Car	15
3.2.1	Ogólny przegląd metod	15
3.2.2	Wpływ parametrów na poszczególne metody	15
3.2.3	Analiza stabilności metod	17
4	Metoda analizy skupień k-medoids	19
4.1	Dane: Computers	19
4.1.1	Ogólny przegląd metod	19
4.1.2	Wpływ parametrów na poszczególne metody	19
4.1.3	Analiza stabilności metod	21

Rozdział 1

Opis eksperymentów

W niniejszym rozdziale rozważono różne sposoby mierzenia odległości dla metody 1-NN oraz metody analizy skupień k-medoids. Pod uwagę zostały wzięte odległości:

- Symbolic Aggregate approXimation (SAX),
- odległość oparta na funkcji autokorelacji (ACF),
- odległość oparta na wzajemnej corelacji (CCor),
- Complexity-Invariant Distance (CID),
- odległość Euklidesowska,
- Dynamic Time Warping (DTW),
- odległość bazująca na współczynniku Fouriera.

W ramach części eksperymentalnej przeprowadzono trzy serie analiz mających na celu ocenę skuteczności wybranych miar odległości. Wszystkie eksperymenty przeprowadzono zarówno z wykorzystaniem algorytmu najbliższego sąsiada (1-NN) jak i algorytmu k-medoids. Analizę przeprowadzono na dwóch rzeczywistych, uprzednio znormalizowanych zbiorach danych: *Computers*, zawierającym obserwacje należące do dwóch klas oraz *Car*, obejmującym cztery klasy.

Pierwszym etapem było zbadanie wpływu doboru parametrów metody Symbolic Aggregate approXimation (SAX) na jej skuteczność. Skoncentrowano się na dwóch kluczowych parametrach: liczbie segmentów `w`, na które dzielony jest szereg czasowy, oraz liczbie poziomów dyskretyzacji `alpha`. W eksperymencie przetestowano kombinacje parametrów `alpha` $\in \{2, 4, 8, 12, 16, 20, 24\}$ oraz `w` $\in \{2, 4, 10, 20, 30, 45, 60\}$. Dla każdej kombinacji przeprowadzono klasyfikację przy użyciu metod 1-NN i k-medoids, a następnie obliczono dokładność predykcji. Uzyskane wyniki zilustrowano w postaci mapy cieplnej, co umożliwiło wizualną ocenę wpływu wartości parametrów na skuteczność metody SAX.

W drugim eksperymencie przeanalizowano metodę opartą na funkcji autokorelacji (ACF), koncentrując się na wpływie parametru `lag.max`, oznaczającego maksymalną liczbę opóźnień uwzględnianych przy obliczaniu ACF. Dla wartości `lag.max` $\in \{1, 2, \dots, 15\}$ przeprowadzono klasyfikację i obliczono dokładność predykcji. Wyniki przedstawiono na wykresie liniowym, umożliwiającym identyfikację optymalnego ustawienia parametru.

W ostatnim kroku przeprowadzono analizę stabilności metod poprzez wielokrotne losowe podziały danych na zbiór treningowy i testowy. Każdy z eksperymentów został powtórzony 20 razy przy losowym podziale danych. Dla każdego powtórzenia obliczono dokładność klasyfikacji, a zebrane wyniki przedstawiono w formie wykresów pudełkowych (boxplotów). Taka prezentacja pozwala

na ocenę nie tylko średniej skuteczności, ale także rozrzutu wyników, co jest istotne przy analizie stabilności i niezawodności badanych metod.


Rozdział 2

Wstępny przegląd danych


2.1 Dane: Computers

Dane pochodzą z badania sponsorowanego przez rząd Wielkiej Brytanii, zatytułowanego „Powering the Nation”. Celem projektu było zebranie informacji na temat zachowań konsumentów związanych z zużyciem energii elektrycznej w gospodarstwach domowych, aby wspomóc działania na rzecz ograniczenia śladu węglowego w kraju. Zarówno zbiór treningowy jak i testowy zawierają pomiary zarejestrowane w 250 gospodarstwach domowych, wykonywane co dwie minuty. Każdy szereg czasowy składa się z 720 obserwacji, odpowiadających 24 godzinom pomiarów wykonywanych w dwuminutowych odstępach. Klasy reprezentują dwa typy urządzeń: komputery stacjonarne (Desktop) i laptopy (Laptop). Dane są znormalizowane, nie zawierają brakujących obserwacji oraz klasy są równoliczne (250/250).

Wizualizacja losowych szeregów z obu klas



Rysunek 2.1: Wizualizacja losowych szeregów z klasy 1 i 2



Rysunek 2.2: Wizualizacja średnich szeregów z klasy 1 i 2

Z rysunków 2.1 i 2.2 możemy wywnioskować, że szeregi z klasy 2 przyjmują większe wartości w godzinach 00:00 - 07:00 oraz mniejsze wartości od 18:00 do 21:00. Zauważalny jest również spadek przyjmowanych wartości w godzinach około 10:00 - 12:00 dla szeregów klasy 2. Dla obu klas widzimy trend wzrostowy w czasie 07:00 - 10:00, chociaż jest on bardziej zauważalny w przypadku szeregów klasy 1. Ponadto szeregi z obu klas notują spadki wartości w godzinach 21:00 - 24:00.

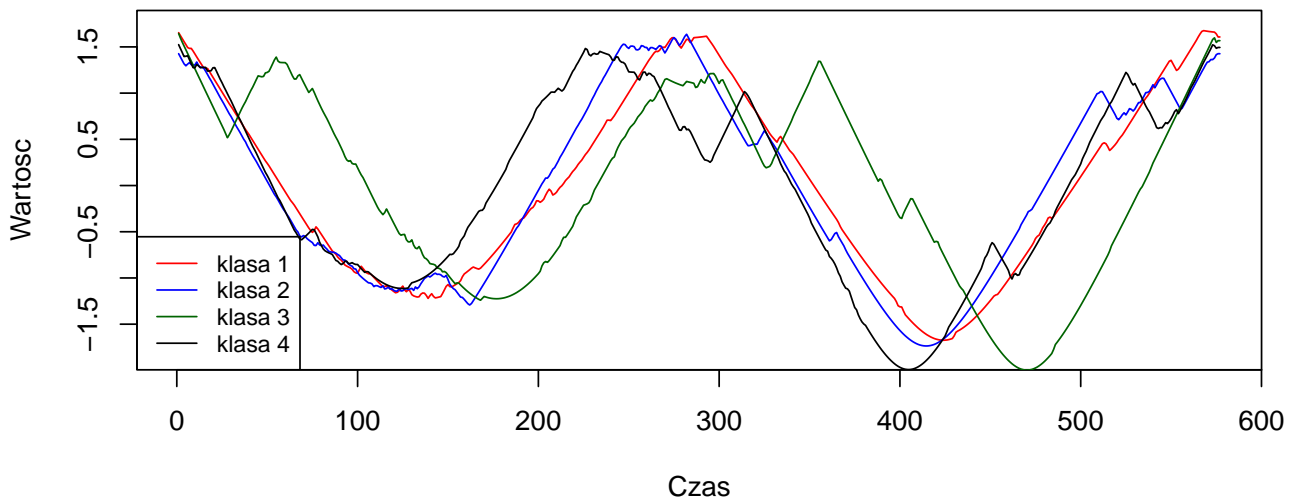
2.2 Dane: Car

Dane pozyskano z nagrań wideo przedstawiających ruch uliczny w warunkach plenerowych. Nagrania te zostały zarejestrowane w rozdzielczości 320×240 pikseli. Na podstawie informacji o ruchu wyodrębniono kontury poruszających się pojazdów. Zastosowana metoda umożliwia ekstrakcję sylwetek pojazdów, jednak nie uwzględnia wpływu cieni, co skutkuje częściowym zniekształceniem dolnych fragmentów uzyskanych kształtów.

Dane obejmują cztery klasy pojazdów: sedan, pickup, minivan oraz SUV. Dla każdej z klas pozyskano po 30 próbek, co łącznie daje 120 obserwacji. W celu ograniczenia wpływu szumu na dalsze przetwarzanie, każdy wyodrębniony kształt został poddany filtracji z wykorzystaniem filtra Gaussa o odchyleniu standardowym równym 5. Dane są znormalizowane.

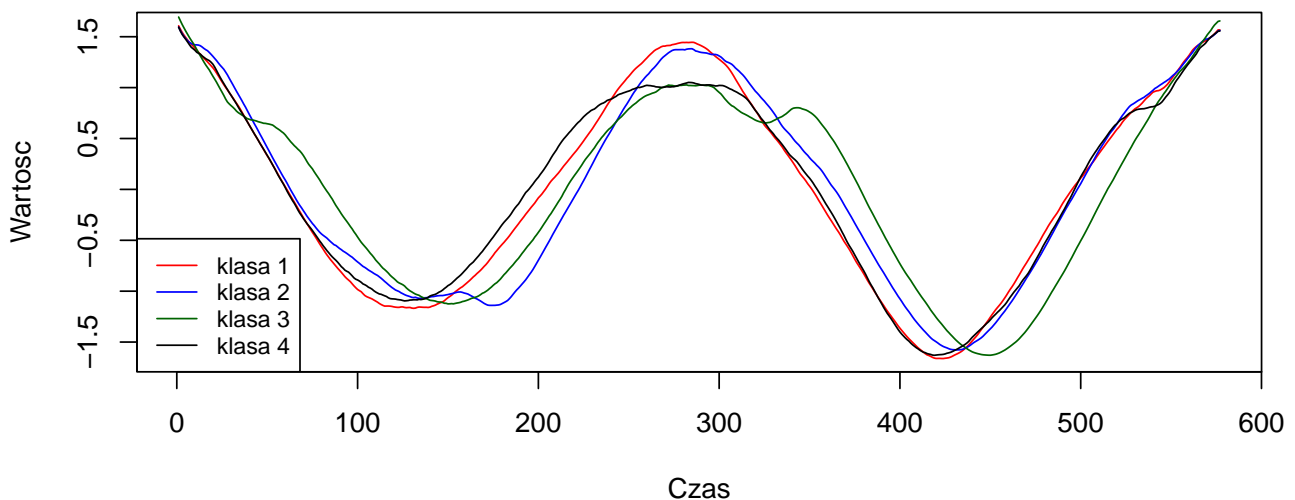
Zestaw danych został następnie losowo podzielony na równoliczne zbiory treningowy oraz testowy.

Wizualizacja losowych szeregów



Rysunek 2.3: Wizualizacja losowych szeregów ze wszystkich klas

Wizualizacja średnich szeregów



Rysunek 2.4: Wizualizacja średnich szeregów ze wszystkich klas

Z rysunku 2.3 możemy zauważyć, że w danych obecna jest wspólna struktura, ale widoczna zmienność. Pomimo że szereg czasowy dla każdej klasy wykazuje pewną wspólną, okresową strukturę (sugerującą obecność cykliczności w ruchu pojazdów), to jednak widoczna jest istotna zmienność pomiędzy poszczególnymi realizacjami – zarówno pod względem amplitudy, jak i przesunięcia. Szeregi z różnych klas wykazują różnice w przebiegu, co może sugerować, że dane zawierają cechy istotne z punktu widzenia klasyfikacji (np. różne typy pojazdów mogą generować inne wzorce ruchu). W niektórych przebiegach widać nieregularności i zakłócenia, co może świadczyć o obecności szumów w surowych danych przed filtracją.

Na rysunku 2.4 widzimy, że uśrednione szeregi są znacznie gładzsze, co jest efektem redukcji szumu oraz zastosowania filtracji i uśredniania. Wszystkie klasy zachowują silnie cykliczny charakter przebiegów. Średnie szeregi czasowe są do siebie podobne, jednak różnią się np. różnicami w amplitudzie lub niewielkimi przesunięciami fazowymi. Może to świadczyć o tym, że klasy są trudne do jednoznacznego rozróżnienia. Mimo ogólnego podobieństwa, pewne różnice mogą stanowić podstawę do dalszej ekstrakcji cech umożliwiających klasyfikację (np. tempo zmian, momenty ekstremalne czy kształt krzywych w określonych przedziałach czasowych).

Rozdział 3

Metoda najbliższego sąsiada 1-NN

3.1 Dane: Computers

3.1.1 Ogólny przegląd metod

Poniższa tabela przedstawia czas wykonania poszczególnych metod oraz ?miary dokładności? dla metody 1-NN, na zbiorze *Computers*.

	time (sec)	accuracy	sensitivity	specificity	precision	recall
ACF	11.20	0.59	0.54	0.65	0.60	0.54
DTW	2696.94	0.66	0.72	0.59	0.64	0.72
Euclidean	14.42	0.58	0.51	0.64	0.59	0.51
SAX	9.83	0.50	0.50	0.50	0.50	0.50
CCor	93.02	0.52	0.62	0.42	0.52	0.62
CID	5.69	0.60	0.54	0.65	0.61	0.54
Fourier	6.20	0.58	0.51	0.64	0.59	0.51

Tabela 3.1: Porównanie wyników klasyfikacji metod na zbiorze *Computers*

Na podstawie wyników przedstawionych w Tabeli 3.1 można sformułować następujące obserwacje dotyczące skuteczności i wydajności poszczególnych metod:


1. **Najwyższą dokładność** (accuracy = 0,66) osiągnęła metoda **DTW**, co czyni ją najskuteczniejszą spośród rozważanych metod pod względem ogólnej poprawności klasyfikacji. Również w zakresie czułości (sensitivity) oraz współczynnika recall metoda DTW uzyskała najwyższe wartości (0,72), co wskazuje na jej dużą skuteczność w wykrywaniu przypadków pozytywnych.
2. **Metody ACF, CID i Fourier** osiągnęły porównywalne wyniki dokładności (w zakresie od 0,58 do 0,60), przy czym charakteryzowały się znacznie krótszym czasem działania niż DTW. Przykładowo, metoda CID wykonała się w zaledwie **5,69 sekundy**, co czyni ją atrakcyjną alternatywą pod względem kompromisu między jakością a wydajnością.
3. **Metoda SAX** uzyskała najniższe wyniki we wszystkich miarach klasyfikacyjnych (accuracy = 0,50, sensitivity = 0,50, specificity = 0,50), co sugeruje, że przy zastosowanych parametrach nie nadaje się do klasyfikacji danych z tego zbioru.

4. **Czas działania** metod istotnie się różnił. Najdłużej wykonywała się metoda DTW - około 45 minut, co może być czynnikiem ograniczającym jej praktyczne zastosowanie ze względu na złożoność obliczeniową.
5. **Metody Euclidean i Fourier** osiągnęły umiarkowaną dokładność (ok. 0,58), przy krótkim czasie działania (od 6 do 14 sekund), co czyni je dobrymi kandydatami do dalszego rozważenia w kontekście klasyfikatorów bazowych.

3.1.2 Wpływ parametrów na poszczególne metody

Metoda Symbolic Aggregate approXimation

W tej sekcji zbadano wpływ parametrów w i α na metodę SAX dla zbioru *Computers*, przy wykorzystaniu algorytmu 1-NN. Wzięto pod uwagę $\alpha \in \{2, 4, 8, 12, 16, 20, 24\}$ oraz $w \in \{2, 4, 10, 20, 30, 45, 60\}$.



Rysunek 3.1: Mapa ciepła przedstawiająca dokładność metody SAX, w algorytmie 1-NN na zbiorze *Computers* w zależności od parametrów

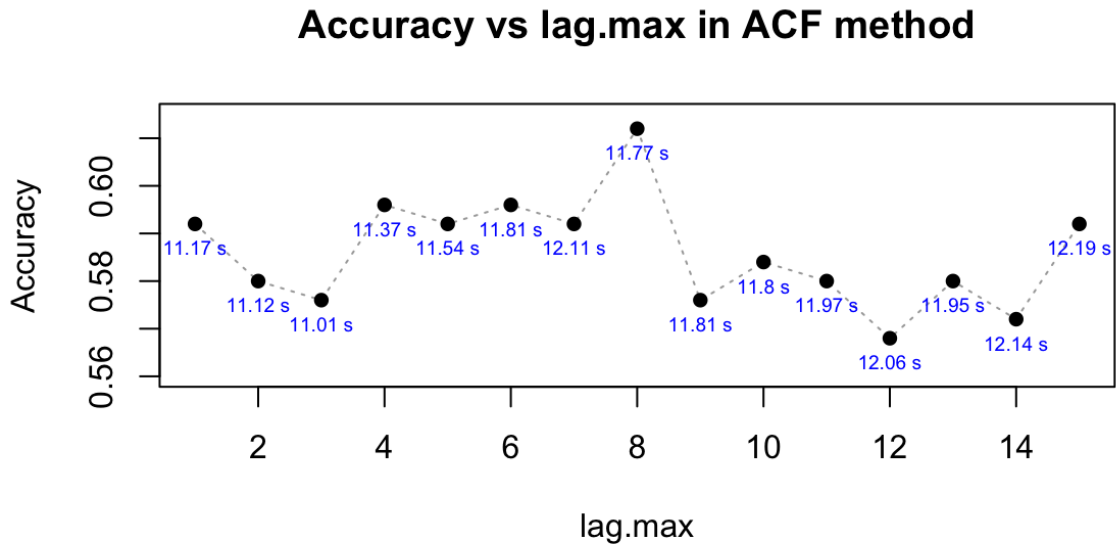
Na podstawie mapy ciepła przedstawionej na rysunku 3.1 można zauważyć, że dokładność metody SAX silnie zależy od odpowiedniego doboru parametrów α i w . Najlepsze wyniki osiągane są przy umiarkowanych wartościach α (około 10–12) oraz mniejszych wartościach w (ok. 10–20). W tym obszarze mapa wskazuje na najwyższy poziom dokładności - około 0,6.

Wraz ze wzrostem wartości w przy niskich α , dokładność istotnie spada. Z kolei zbyt wysokie wartości α również nie wpływają korzystnie na skuteczność metody, co może wynikać z nadmiernego rozdrobnienia danych na symbole, co utrudnia modelowi identyfikację wzorców.

Podsumowując, dla metody SAX optymalny zakres parametrów to umiarkowane α oraz relatywnie niskie w . Dobór tych parametrów ma kluczowe znaczenie dla osiągnięcia wysokiej dokładności klasyfikacji.

Metoda oparta na funkcji autokorelacji

W tej sekcji zbadano wpływ parametru `lag.max` na metodę ACF. Rozpatrzono $\text{lag.max} \in \{1, 2, \dots, 15\}$.



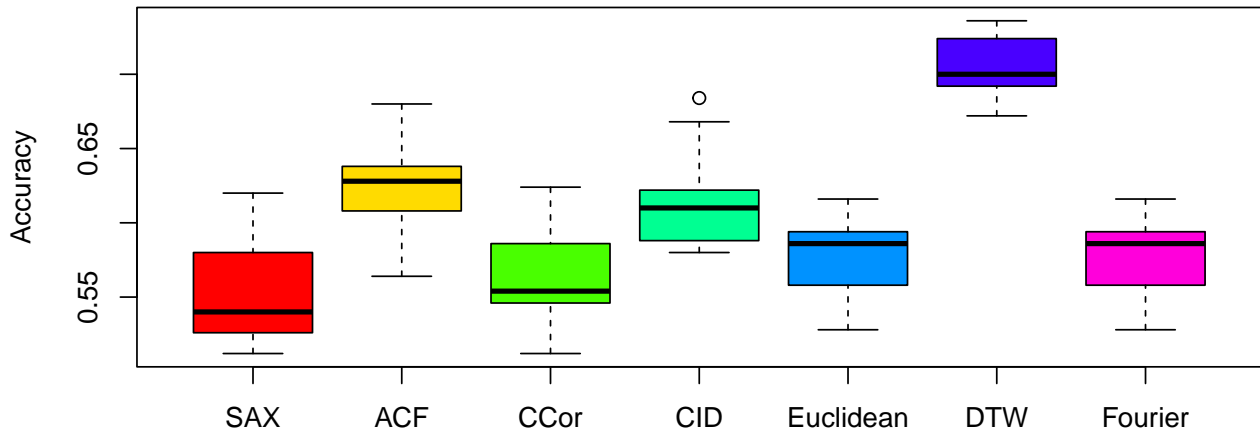
Rysunek 3.2: Wykres dokładności metody ACF w zależności od parametru `lag.max`

Jak możemy zauważyć na rysunku 3.2 dokładność metody SAX na tym zbiorze danych waha się pomiędzy 0,57 a 0,61. Najwyższą dokładność mamy dla `lag.max` = 8. Dość dobre wyniki (w okolicach 0,59) notujemy też dla `lag.max` = {1, 4, 5, 6, 7, 15}. Ponadto warto zwrócić uwagę, że czasy wykonania dla różnych wartości parametru są zbliżone do siebie.

3.1.3 Analiza stabilności metod

W tej sekcji przeprowadzono analizę stabilności metod poprzez 20-krotne losowe podziały danych na zbiór treningowy i testowy. Zostały zachowane oryginalne proporcje zbiorów treningowego i testowego (50/50). Dla każdego powtórzenia obliczono dokładność klasyfikacji. Wyniki przedstawiono w formie wykresów pudełkowych i tabeli ze średnią dokładnością oraz odchyleniem standardowym wyników. W metodzie SAX ustawiono parametry `w`=10 i `alpha`=8, natomiast w metodzie ACF zastosowano `lag.max`=8.

Wykresy pudełkowe dla danych Computers



Rysunek 3.3: Wykresy pudełkowe dokładności dla rozpatrywanych metod, przy 20-krotnym powtórzeniu losowego podziału danych extitComputers

	Średnia	Odchylenie standardowe
SAX	0.55	0.032
ACF	0.63	0.027
CCor	0.56	0.028
CID	0.61	0.028
Euclidean	0.58	0.027
DTW	0.71	0.020
Fourier	0.58	0.026

Tabela 3.2: Średnia i odchylenie standardowe dokładności dla badanych metod

Na podstawie wykresu pudełkowego 3.3 oraz wyników przedstawionych w Tabeli 3.2 można zauważyć wyraźne różnice w skuteczności i stabilności rozpatrywanych metod klasyfikacji.

Najwyższą średnią dokładność klasyfikacji uzyskała metoda **DTW** (0,71), która jednocześnie charakteryzuje się najniższym odchyleniem standardowym (0,02). Oznacza to, że DTW nie tylko osiąga najlepsze wyniki, ale również wykazuje bardzo wysoką stabilność względem losowego podziału danych.

Na drugim miejscu pod względem dokładności znajduje się metoda **ACF** ze średnią dokładnością 0,63. Cechuje się stosunkowo niską zmiennością wyników z odchyleniem standardowym 0,027. Podobne właściwości wykazuje metoda **CID**. Tutaj mamy średnią 0,61 i odchylenie 0,028, co czyni ją również godną uwagi.

Najniższą średnią dokładność na poziomie 0,55 uzyskała metoda **SAX**. Dodatkowo wykazuje ona najwyższe odchylenie standardowe na poziomie 0,032, co świadczy o jej niskiej stabilności. Również metoda **CCor**, mimo niskiej dokładności (średnio 0,56), cechuje się dość dużą zmiennością wyników na poziomie 0,028.

Pozostałe metody, takie jak **Euclidean** i **Fourier**, osiągają umiarkowaną średnią dokładność 0,58 i niskie odchylenia standardowe - odpowiednio 0,027 i 0,026. Wskazuje to na ich stabilność, choć niekoniecznie wysoką skuteczność.

Podsumowując, metoda **DTW** zdecydowanie wyróżnia się pod względem zarówno skuteczności, jak i niezawodności. Na przeciwnym biegunie znajduje się metoda **SAX**, która wypada najsłabiej w obu aspektach.

3.2 Dane: Car

3.2.1 Ogólny przegląd metod

Poniższa tabela przedstawia czas wykonania poszczególnych metod oraz ?miary dokładności? dla zbioru *Car*.

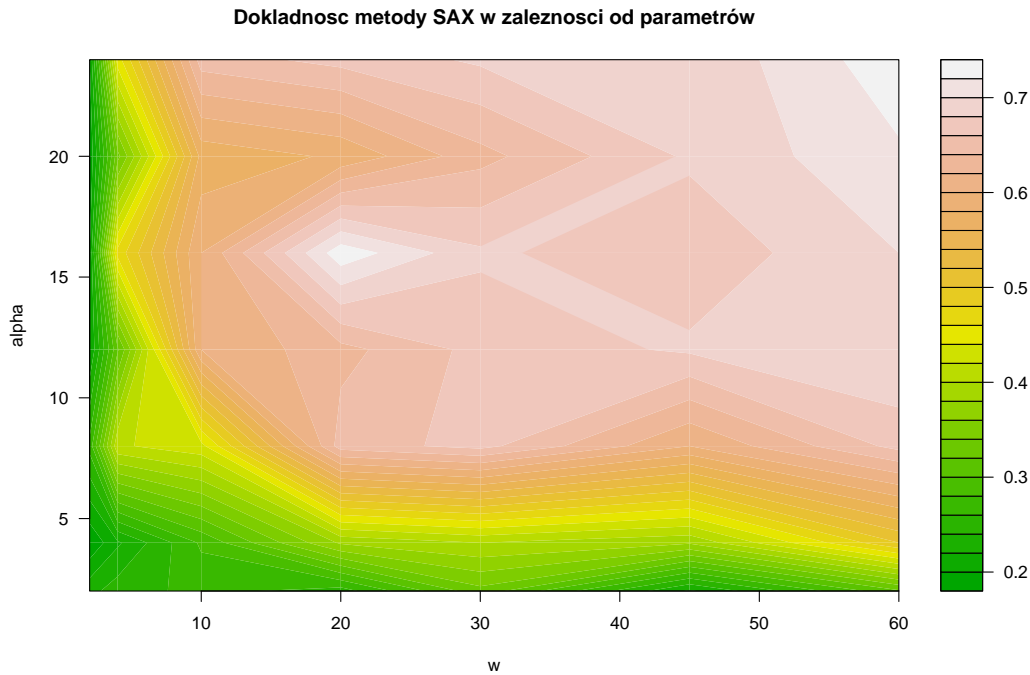
	time (sec)	accuracy	sensitivity	specificity	precision	recall
ACF	1.57	0.45	0.50	0.50	0.85	0.74
DTW	110.14	0.73	0.71	0.86	0.89	0.96
Euclidean	1.93	0.73	0.79	0.86	0.85	0.98
SAX	1.19	0.47	0.50	0.36	0.80	0.85
CCor	8.66	0.73	0.79	0.86	0.85	0.98
CID	0.43	0.73	0.79	0.86	0.85	0.98
Fourier	1.16	0.73	0.79	0.86	0.85	0.98

Tabela 3.3: Porównanie wyników klasyfikacji metod na zbiorze *Car*.

3.2.2 Wpływ parametrów na poszczególne metody

Metoda Symbolic Aggregate approXimation

W tej sekcji zbadano wpływ parametrów w i α na metodę SAX dla zbioru *Car*. Tak jak w przypadku poprzedniego zbioru danych, wzięto pod uwagę $\alpha \in \{2, 4, 8, 12, 16, 20, 24\}$ oraz $w \in \{2, 4, 10, 20, 30, 45, 60\}$.




Rysunek 3.4: Mapa ciepła przedstawiająca dokładność metody SAX w algorytmie 1-NN na zbiorze *Car* w zależności od parametrów

Z mapy ciepła 3.4 możemy wywnioskować, że najlepsze wyniki (dokładność powyżej 0.7) uzyskano w prawym górnym rogu mapy, tj. dla największych wartości parametrów **alpha** oraz **w**. Oznacza to, że zwiększenie liczby symboli oraz długości okna agregacji poprawia skuteczność metody SAX na zbiorze *Car*. Na mapie możemy również zauważyć pewnego rodzaju maksimum lokalne dla parametrów **alpha** = 16 i **w** = 20. Najniższe wartości (poniżej 0,3) występują przy małych wartościach obu parametrów, co sugeruje, że zbyt silne uproszczenie reprezentacji czasowej powoduje utratę informacji niezbędnych do poprawnej klasyfikacji. Zarówno zwiększenie liczby symboli (parametr **alpha**) jak i długości okna agregacji (parametr **w**) przyczynia się do poprawy jakości klasyfikacji. Sugeruje to, że dla analizowanego zbioru korzystne jest zachowanie większej ilości szczegółów w symbolicznym odwzorowaniu danych.

Metoda oparta na funkcji autokorelacji

W tej sekcji zbadano wpływ parametru `lag.max` na metodę ACF przy danych *Car*. Ponownie rozpatrzono $\text{lag.max} \in \{1, 2, \dots, 15\}$.




Rysunek 3.5: Wykres dokładności metody ACF w zależności od parametru `lag.max` na danych *Car*

Jak możemy zauważyć na rysunku 3.5 dokładność metody ACF na tym zbiorze danych waha się pomiędzy 0,31 a 0,45. Najwyższą dokładność otrzymujemy dla parametru `lag.max` = 5. Wyższe wyniki notujemy również dla `lag.max` = {4, 14, 15}. Podobnie jak wcześniej, czasy wykonania dla różnych wartości parametru są zbliżone do siebie, chociaż wyraźnie niższe niż w przypadku danych *Computers*.

3.2.3 Analiza stabilności metod

W tej sekcji przeprowadzono analizę stabilności metod na danych *Car* poprzez 20-krotne losowe podziały danych na zbiór treningowy i testowy. Zostały zachowane oryginalne proporcje zbiorów treningowego i testowego czyli 60/60. Dla każdego powtórzenia obliczono dokładność klasyfikacji. Wyniki przedstawiono w formie wykresów pudełkowych i tabeli ze średnią dokładnością oraz odchyleniem standardowym wyników. W metodzie SAX ustawiono parametry `w` = 20 i `alpha` = 16, natomiast w metodzie ACF zastosowano `lag.max` = 5.

Wykresy pudełkowe dla danych Car



Rysunek 3.6: Wykresy pudełkowe dokładności dla rozpatrywanych metod, przy 20-krotnym powtórzeniu losowego podziału danych *Car*

	Średnia	Odchylenie standardowe
SAX	0.66	0.044
ACF	0.41	0.072
CCor	0.74	0.035
CID	0.74	0.038
Euclidean	0.73	0.036
DTW	0.67	0.049
Fourier	0.73	0.036

Tabela 3.4: Średnia i odchylenie standardowe dokładności dla badanych metod na zbiorze *Car*

Rozdział 4

Metoda analizy skupień k-medoids

4.1 Dane: Computers

4.1.1 Ogólny przegląd metod

Poniższa tabela przedstawia czas wykonania poszczególnych metod oraz ?miary jakości? dla zbioru *Computers*.

	time (sec)	accuracy	sensitivity	specificity	precision	recall
ACF	62.27	0.53	0.13	0.94	0.67	0.13
DTW	5864.19	0.63	0.51	0.75	0.67	0.51
Euclidean	62.55	0.51	0.55	0.47	0.51	0.55
SAX	25.38	0.54	0.09	0.98	0.85	0.09
CCor	409.50	0.53	0.07	0.98	0.78	0.07
CID	18.50	0.55	0.22	0.88	0.65	0.22
Fourier	13.07	0.51	0.55	0.47	0.51	0.55

Tabela 4.1: Porównanie wyników klasyfikacji metod na zbiorze *Computers*, przy wykorzystaniu algorytmu k-medoids

Z tabeli 4.1 możemy odczytać, że wszystkie metody osiągnęły podobny poziom accuracy (od 0,5 do 0,63), co sugeruje umiarkowaną jakość klasyfikacji na tym zbiorze. Najwyższą dokładność osiągnęła metoda **DTW** (accuracy = 0,63), ale jej koszt czasowy był bardzo wysoki (ponad 1,5 h).


Metody **CCor** i **SAX** uzyskały najlepsze wyniki w zakresie specificity, ale ich wartości sensitivity i recall były niskie. Metody **Euclidean** i **Fourier** uzyskały zrównoważone wartości miar, co wskazuje na ich stabilność, choć nie najwyższą skuteczność.

Najszybsza była odległość **Fourier** (13,07 s) przy zachowaniu umiarkowanej skuteczności. **CID** również działała szybko (18,5 s) i osiągnęła nieco wyższą dokładność niż **ACF**, **SAX** czy **Euclidean**.

4.1.2 Wpływ parametrów na poszczególne metody

Metoda Symbolic Aggregate approXimation

W tej sekcji zbadano wpływ parametrów w i α na metodę SAX dla zbioru *Computers*, przy wykorzystaniu algorytmu k-medoids. Wzięto pod uwagę $\alpha \in \{2, 4, 8, 12, 16, 20, 24\}$ oraz $w \in \{2, 4, 10, 20, 30, 45, 60\}$.




Rysunek 4.1: Mapa ciepła przedstawiająca dokładność metody SAX w algorytmie k-medoids na zbiorze *Computers* w zależności od parametrów

Mapa ciepła 4.1 wskazuje na wyraźną zależność skuteczności SAX od właściwego doboru obu parametrów. Najwyższe wartości dokładności (powyżej 0,6) zostały osiągnięte przy niskich wartościach parametru w (około 4) oraz przy wysokich wartościach α (około 24). Przy wysokich wartościach w (powyżej 45), dokładność dla średnich α spada, co wskazuje, że zbyt duże rozmiary segmentów mogą negatywnie wpływać na skuteczność metody. Dla bardzo niskich wartości α dokładność jest ogólnie niższa, niezależnie od w .

Metoda oparta na funkcji autokorelacji

W tej sekcji zbadano wpływ parametru `lag.max` na metodę ACF dla algorytmu k-medoids i danych *Computers*. Tak jak poprzednio rozpatrzono $\text{lag.max} \in \{1, 2, \dots, 15\}$.



Rysunek 4.2: Wykres dokładności metody ACF w zależności od parametru lag.max na danych *Computers* dla algorytmu k-medoids

Na rysunku 4.2 możemy zauważyć, że dokładność ACF na tym zbiorze danych waha się pomiędzy 0,51 a 0,544. Najwyższą dokładność obserwujemy dla $\text{lag.max} = 1$. Dla wartości od 1 do 10 obserwujemy ciągły spadek dokładności. Od 10 do 15 mamy z kolei wzrost do poziomu około 0,53 dla $\text{lag.max} = 15$.

4.1.3 Analiza stabilności metod